

Расстояние редактирования текстового дерева: сравнение текстовых иерархий с использованием языковых моделей

Соболевский Ф. А.¹, д. ф.-м. н. Воронцов К. В.^{1,2}

¹Московский физико-технический институт

²Московский государственный университет им. М. В. Ломоносова

2025

Мотивация исследования

A new algorithm for text tree edit distance based on Zhang-Shasha's algorithm and BERT-like model embedding similarity.

The algorithm's novelty is in its similarity measure based on BERT-like model embeddings.

Embedding distance is used as a measure of semantic similarity.

The proposed algorithm is presented as a more informative metric of similarity between text trees.

The language model allows to capture semantic meaning of sentences and model their similarity.

Zhang-Shasha's algorithm is used to compute tree edit distance with new edit costs.

The current ways of comparing text trees overlook overestimate their tree structure or the meaning of their labels.

This new method can be used, for example, to compare mind maps or hierarchical summaries.

Semantic similarity is used as the update cost in the algorithm.

The costs of insertion and removal of nodes are defined as the similarity of the node and an empty sentence.

Пример текстового дерева — иерархическая сводка данного исследования в виде интеллект-карты

Проблема: как сравнивать иерархические сводки между собой, учитывая как их структуру, так и семантику?

Постановка задачи иерархической суммаризации

Пусть \mathcal{S} — множество текстов над заданным словарем.

Текстовое дерево — дерево $T = (V, E)$, где $E \subset V^2$ и для каждого $v \in V$ определен текст $s(v) \in \mathcal{S}$.

\mathcal{T} — рассматриваемое множество текстовых деревьев.

Задача: найти отображение $f : D \mapsto T$, строящее иерархическую сводку $T \in \mathcal{T}$ по документу D , минимально отличающуюся от эталонной сводки T^* , построенной экспертом:

$$\rho(f(D), T^*) \longrightarrow \min_f .$$

Вопрос: как выбрать метрику $\rho : \mathcal{T}^2 \rightarrow \mathbb{R}_+$?

Требования к метрике на множестве текстовых деревьев

Пусть задана функция **семантического (смыслового) расстояния** между текстами: $r : \mathcal{S}^2 \rightarrow [0, +\infty)$.

Обозначение: $r(v, v') := r(s(v), s(v'))$, а $r(v) := r(s(v), \lambda)$, где λ — пустая строка.

Требования к метрике $\rho : \mathcal{T}^2 \rightarrow \mathbb{R}_+$:

1. ρ является корректной метрикой на \mathcal{T} .
2. Пусть $T, T' \in \mathcal{T}$. Существует некоторая неубывающая функция $f : [0, +\infty) \rightarrow [0, +\infty)$, такая что:
 - 2.1 Если T' получено из T добавлением в T вершины v , то $\rho(T, T') = f(r(v))$;
 - 2.2 Если T' получено из T удалением из T вершины v , то $\rho(T, T') = f(r(v))$;
 - 2.3 Если T' получено из T заменой вершины v на v' , то $\rho(T, T') = f(r(v, v'))$.

Предлагаемая метрика — *TTED*

TTED (*text tree edit distance*) — расстояние редактирования¹, где стоимость операций редактирования:

- а) замены вершины v на v' : $r(s(v), s(v'))$;
- б) добавления/удаления вершины v : $r(s(v), \lambda)$;

где λ — пустая строка.

Семантическое расстояние r можно измерять как расстояние между эмбеддингами (векторными представлениями) текстов, полученными с помощью языковой модели $\text{LM} : \mathcal{S} \rightarrow \mathbb{R}^n$:

$$\forall s, s' \in \mathcal{S} \quad r(s, s') = \rho_n(\text{LM}(s), \text{LM}(s')),$$

где ρ_n — метрика в \mathbb{R}^n .

¹Zhang Kaizhong, Statman Richard, Shasha Dennis. On the Editing Distance Between Unordered Labeled Trees (1992)

Базовый метод сравнения текстовых деревьев

В работе *Zhang et al., 2024*² близость текстовых деревьев $T = (V, E)$ и $T' = (V', E')$ определяется как

$$\text{Sim}(T, T') = \max_{P \subset E \times E'} \sum_{(e, e') \in P} \sum_{i=0,1} \text{ROUGE}(e_i, e'_i).$$

где P — однозначное сопоставление ребер T ребрам T' (оптимальное ищется жадным алгоритмом), $\text{ROUGE}(v, v')$ — усредненная оценка ROUGE-1, ROUGE-2 и ROUGE-L сходства $s(v)$ и $s(v')$.

Для единообразия в качестве оценки расстояния используется

$$\rho(T, T') = \sqrt{\text{Sim}(T, T) + \text{Sim}(T', T') - \text{Sim}(T, T') - \text{Sim}(T', T)}.$$

²*Zhang Zhuowei, Hu Mengting, Bai Yinhao, and Zhang Zhen. Coreference Graph Guidance for Mind-Map Generation (2024)*

Аспекты различия текстовых деревьев

Пусть для $T \in \mathcal{T}$ заданы множества деревьев:

1. $P(T)$ — отличающихся от T только перефразированием;
2. $S(T)$ — отличающихся от T только структурой;
3. $M(T)$ — отличающихся от T только семантикой (по смысловому содержанию).

Идея: для адекватной метрики ρ на \mathcal{T} должно выполняться

$$\langle \rho(T, T') \rangle_{T' \in P(T)} \ll \langle \rho(T, T'') \rangle_{T'' \in S(T)},$$

$$\langle \rho(T, T') \rangle_{T' \in P(T)} \ll \langle \rho(T, T''') \rangle_{T''' \in M(T)}.$$

Критерии качества метрики

Рассмотрим выборку

$$\mathcal{D} = \{T, T'_1, \dots, T'_p, T''_1, \dots, T''_s, T'''_1, \dots, T'''_m\}, \text{ где } T \in \mathcal{T}, \\ T'_j \in P(T), T''_j \in S(T), T'''_k \in M(T).$$

Коэффициенты качества метрики ρ по выборке \mathcal{D} :

$$R_S^{\mathcal{D}}(\rho) = \frac{1}{sp} \sum_{i=1}^p \sum_{j=1}^s \frac{\rho(T, T'_i)}{\rho(T, T''_j)}, \quad R_M^{\mathcal{D}}(\rho) = \frac{1}{mp} \sum_{i=1}^p \sum_{k=1}^m \frac{\rho(T, T'_i)}{\rho(T, T'''_k)}.$$

$R_S^{\mathcal{D}}(\rho)$ — чувствительность метрики ρ к **парафразированию** по отношению к **структуре**;

$R_M^{\mathcal{D}}(\rho)$ — чувствительность к **парафразированию** по отношению к **семантике**.

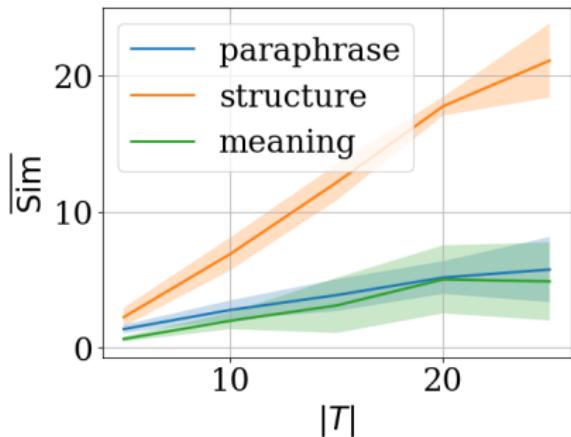
Оптимизационная задача:

$$R_S^{\mathcal{D}}(\rho) \rightarrow \min_{\rho}, \quad R_M^{\mathcal{D}}(\rho) \rightarrow \min_{\rho}.$$

Тестирование метрик — результаты

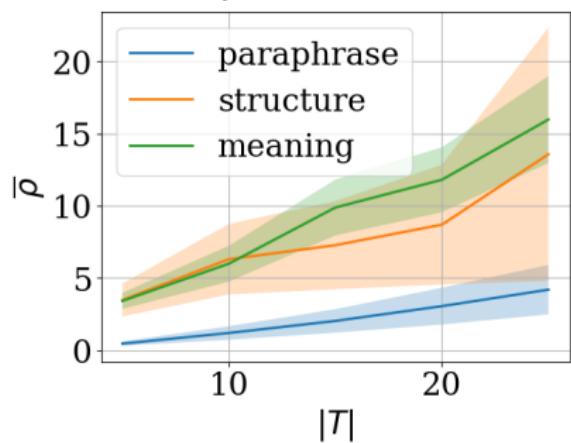
Зависимость от размера дерева $|T|$:

- а) средних значений базового коэффициента сходства



$Sim(\cdot, \cdot)$ сходно отражает различия по семантике и парофразированию, заметно меньше — по структуре.

- б) средних расстояний по метрике TTED



TTED отражает различия по парофразированию заметно меньше, чем по структуре и семантике.

Тестирование метрик — результаты

Результаты тестирования базового метода и TTED с разными моделями-кодировщиками для получения эмбеддингов текстов на синтетических данных

Модель	$R_S^{\mathcal{D}}(\rho)$	$R_M^{\mathcal{D}}(\rho)$
Базовый метод	$1,44 \pm 0,25$	$0,89 \pm 0,03$
TTED с DistilRoBERTa	$0,54 \pm 0,13$	$0,61 \pm 0,10$
TTED с SPECTER	$0,45 \pm 0,10$	$0,41 \pm 0,06$
TTED с MPNet	$0,40 \pm 0,11$	$0,42 \pm 0,08$
TTED с дообученной MPNet	$0,38 \pm 0,16$	$0,36 \pm 0,04$

Значимые отличия в сравнении с незначительными отражаются TTED лучше, чем базовым методом.

Тестирование модификаций TTED

Зависимость коэффициентов качества от метрики для сравнения эмбеддингов в TTED

$r(x, y)$	$\bar{\rho}_1$	$\bar{\rho}_3$	$R_M^D(\rho)$
$\sqrt{1 - S_C(x, y)}$	1,82	7,56	0,24
$\ x - y\ _2$	7,34	30,22	0,24
$\ x - y\ _1$	157,09	617,63	0,25

Зависимость коэффициентов качества от использования контекста в TTED

Метод	$\bar{\rho}_1$	$\bar{\rho}_2$	$\bar{\rho}_3$	$R_S^D(\rho)$	$R_M^D(\rho)$
Без контекста	1,25	4,80	4,34	0,32	0,29
С контекстом	1,82	7,71	7,56	0,24	0,24

Оптимальной и наиболее интерпретируемой конфигурацией TTED является конфигурация с кодировщиком MPNet, расстоянием на основе косинусного коэффициента и с использованием контекста в виде родительских вершин.

Основные результаты

1. Предложена новая метрика на множестве текстовых деревьев — TTED.
2. Показано, что TTED лучше отражает значимые различия текстовых деревьев, чем использованный до этого коэффициент сходства.
3. Подобрана оптимальная конфигурация TTED.
4. Предложенную метрику можно использовать для оценки качества в задачах иерархической суммаризации, построения интеллект-карт и других задачах автоматической генерации текстовых иерархий.

Литература

- ▶ *Zhang Z., Hu M., et al.* Coreference Graph Guidance for Mind-Map Generation // Proceedings of the AAAI Conference on Artificial Intelligence. — 2024. — Vol. 38. — P. 19623–19631.
- ▶ *Zhang K., Statman R., Shasha D.* On the editing distance between unordered labeled trees. // Information processing letters. 1992 May 25; 42(3): 133-9.
- ▶ *Vrbanec T., Meštrović A.* Comparison study of unsupervised paraphrase detection: Deep learning — The key for semantic similarity detection. // Expert systems. 2023 Nov; 40(9): e13386.